



北京航空航天大学
B E I H A N G U N I V E R S I T Y

毕业设计(开题报告)

抗干扰目标识别的主动视角规划算法研究

学 院 名 称	航空科学与工程学院
专 业 名 称	飞行器控制与信息工程
学 生 姓 名	刘 帝
指 导 教 师	王 琦 少

2026 年 3 月

目 录

1 选题依据	1
1.1 研究背景及意义	1
1.2 研究现状分析	2
1.2.1 传统目标检测与跟踪算法	2
1.2.2 传统轨迹预测算法	3
1.2.3 传统云台视角规划与控制算法	5
2 研究内容	6
2.1 多传感器融合目标检测与跟踪	6
2.1.1 激光雷达和相机数据的融合策略调研	6
2.1.2 多传感器融合技术路线拟定	7
2.2 IMM-KF 轨迹预测算法	8
2.2.1 IMM-KF 算法原理	8
2.2.2 匀速运动模型(CV)	9
2.2.3 匀加速度运动模型(CA)	10
2.2.4 Singer 模型	10
2.3 MPC 主动视角规划算法	10
2.3.1 问题描述	10
2.3.2 代价函数构建	11
3 研究方案	11
3.1 研究方法与技术途径	11
3.2 研究的创新之处	12
4 研究计划及预期成果	12
4.1 研究计划	12
4.2 预期成果	12
参考文献	14

1 选题依据

1.1 研究背景及意义

近年来，随着自动化技术、嵌入式计算技术、无线通信技术以及人工智能技术的迅速发展，无人机（Unmanned Aerial Vehicle，简称 UAV）在感知能力、自主决策能力以及协同作业能力等方面取得了显著进展。得益于飞行控制技术的不断成熟、轻量化材料与结构设计水平的提升，以及高性能传感器与嵌入式计算平台成本的持续下降，无人机系统正朝着小型化、智能化和低成本化方向快速发展。相比传统有人航空器，无人机具有体积小、机动性强、部署灵活、操作门槛低、维护成本相对较低等优势，在实际应用中展现出极高的效率。当前，无人机的应用范围已经从早期以军事侦察、战术打击和情报侦察为主的军用领域，逐渐扩展至更加广泛的民用场景，例如航拍摄影与影视制作、地理测绘与三维建模、电力线路与输油管道巡检、农业植保作业、物流配送、环境监测以及应急救援等多个领域。在智慧城市建设和低空经济快速发展的背景下，无人机正逐渐成为空中作业的重要工具，无人机相关的产业规模也在持续扩大。

然而，在带来巨大社会经济价值的同时，无人机技术的发展也催生了一系列的安全隐患与监管问题。由于无人机具有体积小、机动性强、飞行高度低、机动性高等特点，一些未经许可的飞行活动难以及时被监管部门发现与管理。在城市及人口密集区域，违规“黑飞”、超视距飞行以及擅自进入机场周边、政府机关、重要基础设施等敏感区域的事件时有发生；此外，部分不法分子甚至利用无人机实施偷拍、走私、投放危险物品等违法犯罪行为；在机场、发电厂、油气设施等关键基础设施附近，无人机的异常活动也可能引发严重的安全事故。因此，如何在复杂环境中对低空无人机进行及时、准确的探测与跟踪，已经成为当前公共安全管理和低空空域管理中的重要问题。

在此背景下，低空无人机监测技术逐渐成为国内外研究的热点方向。低空无人机监测系统通常由多个功能模块构成，包括目标检测、目标跟踪、态势评估以及预警处置等环节，其系统流程如图 1 所示^[1]。其中，目标检测与目标跟踪是整个系统的基础和关键环节，其性能直接影响后续态势分析与决策的准确性。




图1 低空无人机监测系统^[1]

然而，在复杂环境下实现对低空无人机的稳定检测与持续跟踪仍然面临诸多技术挑战。首先，大多数消费级无人机体积较小、结构简单，在远距离观测条件下往往只占据图像中的少量像素，属于典型的弱小目标。此类目标在图像中易与背景噪声混淆，导致检测算法难以稳定识别。其次，在实际监测场景中，天空背景往往存在云层变化、光照变化以及各种干扰目标，这些因素都会增加目标检测与识别的难度。此外，无人机在飞行过程中通常具有较高的机动性，其运动轨迹可能出现快速转弯、突然加减速等复杂变化，这对目标跟踪算法的鲁棒性与实时性提出了更高要求。在多目标场景下，还可能出现目标交叉、遮挡以及短时丢失等情况，使得稳定跟踪变得更加困难。

因此，针对复杂环境下弱小无人机目标的高精度检测与鲁棒跟踪开展深入研究，具有重要的理论意义与工程应用价值。一方面，从理论研究角度来看，弱小目标在图像中信息量有限、特征不明显，其检测与跟踪问题涉及小目标特征表达、复杂背景抑制以及多目标运动轨迹预测等关键技术，对目标检测与跟踪算法的设计提出了更高要求。通过研究适用于弱小目标场景的检测与跟踪方法，可以进一步丰富和完善小目标视觉感知与运动预测相关理论。另一方面，从工程应用角度来看，提升系统在复杂背景、多目标干扰以及低信噪比条件下的检测与跟踪能力，可以显著提高低空无人机监测系统的稳定性与实时性，为低空空域安全监管、重要区域安全防护以及公共安全管理等应用提供可靠的技术支撑。

1.2 研究现状分析

低空无人机探测需求随无人机广泛使用日益提升，在该任务场景中，利用光电传感器或其他探测设备对空域目标进行持续监测，并对潜在威胁目标进行及时发现与跟踪，是系统实现有效管理与安全防护的重要基础。在实际应用中，由于无人机目标通常具有体积小、飞行高度低以及机动性强等特点，监测系统需要在复杂背景环境下实现对弱小目标的稳定检测与持续跟踪。此外，在目标被检测到之后，还需要对其运动状态进行估计并预测其未来轨迹，以便对目标行为进行分析和评估。同时，在预测其未来轨迹之后，检测系统还需要控制自身视角以保持目标的持续跟踪，国内外就目标检测与跟踪、轨迹预测、云台视角控制三个领域开展了大量算法研究，目标实现更快速更高效更精确的无人机监测算法。

1.2.1 传统目标检测与跟踪算法

针对低空无人机检测与跟踪任务，传统的目标检测与跟踪算法流程图如图 2 所示^[2]。首先，由高分辨率 PTZ 相机获取二维视觉输入，向检测模块传输连续的二维图像序列；然后，目标检测模块使用离线训练好的神经网络进行目标检测任务，对视频的每一帧生成准确可靠的检测结果，但帧间数据缺少关联性，计算机无法将其识别为同一个物体；最后，目标跟踪模块同归检测连续两帧检测结果之间两个目标检测框的交并比、置信度等信息进行数据关联，当满足条件则视为是同一个目标。




图2 传统目标检测与跟踪算法流程图^[2]

使用相机获取的二维视觉信息对低空无人机进行检测与跟踪已经成为低空无人机检测任务研究的重要方向。随着计算机视觉和深度学习技术的发展，研究者提出了大量基于视觉的无人机检测与跟踪算法，通过分析图像序列中的外观特征和时序信息，实现对无人机目标的位置估计与轨迹获取。为了推动该领域的发展，中科大赵健团队构建了一个大规模视觉无人机跟踪基准数据集^[3]，该数据集包含 300 余对视频序列以及超过 58 万个手工标注的目标边界框，包含多种复杂背景场景，如城市、云层以及植被等环境。基于该数据集，作者还提出了一种双流语义一致性（Dual-Flow Semantic Consistency, DFSC）跟踪方法，通过利用视频序列中的语义信息和时序特征提升跟踪鲁棒性。实验结果表明，该基准数据集具有较高挑战性，为视觉无人机跟踪算法的研究与评估提供了重要平台，并推动了低空无人机检测视觉感知技术的发展。

然而，传统的二维视觉无人机检测方法仍然存在较为明显的局限性。首先，二维视觉系统高度依赖环境光照条件，当监测环境出现昼夜变化、逆光、阴雨天气或雾霾等复杂气象条件时，图像质量往往会明显下降，容易出现目标对比度降低、细节信息丢失以及噪声增强等问题。在这种情况下，无人机目标本身尺寸较小、纹理特征不明显，极易与复杂背景中的云层、鸟类或其他飞行物体混淆，从而降低检测算法的稳定性与准确性，甚至导致目标漏检或误检。其次，仅依赖二维视觉信息通常只能获取目标在图像平面中的像素位置，缺乏可靠的深度信息，难以准确估计无人机与监测设备之间的真实空间距离。这不仅会影响目标定位精度，也会给后续的运动状态估计带来较大误差。此外，对于机动性较强的无人机目标，其运动轨迹往往具有快速变化的特点，仅凭二维视觉信息难以建立精确的运动模型，从而限制了对无人机未来轨迹进行有效预测的能力。因此，在复杂监测环境下，仅依靠传统二维视觉方法难以满足高精度无人机监测与跟踪的实际需求。

1.2.2 传统轨迹预测算法

传统的轨迹预测算法主要分为两大类：基于物理的轨迹预测算法与基于学习的轨迹预测算法，如图 3 所示^[4]。




图3 传统轨迹预测算法总览^[4]

1.2.2.1 基于物理模型的轨迹预测方法（Physics-based Methods）

基于物理模型的轨迹预测方法（Physics-based Methods）是目标运动预测领域中较为经典的一类方法，其核心思想是利用物理运动规律或运动学模型，对目标未来的运动状态进行估计与预测。这类方法通常通过构建描述目标运动过程的数学模型，并结合当前观测到的状态信息，对未来一段时间内的轨迹进行推算。

其中，单轨迹(Single-Trajectory)方法是一种较为基础的预测方式^[5]，该方法通常直接利用目标当前的运动状态，并结合预先设定的运动学或动力学方程（如匀速模型、匀加速模型等）对未来轨迹进行外推。这类方法实现简单、计算效率高，但由于仅依赖单一运动模型，当目标运动状态发生变化时，其预测精度容易受到影响。

为了进一步考虑状态估计中的不确定性，研究人员提出了基于卡尔曼滤波(Kalman Filter)的轨迹预测方法^[6]。该方法通过建立状态空间模型，对目标的状态进行递归估计。在预测阶段，系统根据运动模型对目标状态进行外推，同时考虑系统噪声导致的不确定性增加；在更新阶段，当新的观测数据到达时，通过滤波更新过程修正预测结果，从而减小状态估计误差。由于其计算效率较高且具有良好的实时性，卡尔曼滤波及其扩展形式被广泛应用于目标跟踪与轨迹预测任务中。

此外，蒙特卡罗方法(Monte Carlo Methods)通过对输入变量进行随机采样，并结合物理运动模型生成大量可能的未来轨迹，以此来近似目标状态的概率分布。与单一轨迹预测方法相比，该方法能够更好地描述目标未来运动的不确定性，因此在复杂动态环境下具有更强的适应能力。

1.2.2.2 基于学习的轨迹预测方法（Learning-based Methods）

与基于物理模型的轨迹预测方法相比，基于学习的方法（Learning-based Methods）主要通过从大量历史数据中学习目标的运动规律，从而建立运动动力学模型并进行轨迹预测。这类方法能够从数据中自动提取复杂的运动模式，因此在处理复杂场景或非线性运动行为时具有更强的表达能力。根据所采用的学习框架不同，基于学习的轨迹预测方法通常可以分为经典机器学习方法、深度学习方法以及强化学习方法三类。

首先，经典机器学习（Machine Learning, ML）方法通过构建函数逼近模型，从历史轨迹数据中学习目标的运动规律。例如，利用概率模型或统计学习方法对目标的运动状态进行建模，从而实现未来轨迹预测。在现有研究中，较为典型的方法包括高斯过程（Gaussian Process）、隐马尔可夫模型（Hidden Markov Model, HMM）、动态贝叶斯网络（Dynamic Bayesian Network）以及高斯混合模型（Gaussian Mixture Model, GMM）等。这类方法通常能够在一定程度上刻画目标运动过程中的不确定性，并通过概率分布描述未来轨迹的可能性。然而，由于模型表达能力有限，当场景复杂或数据维度较高时，其性能可能受到一定限制。

其次，随着深度学习技术的发展，基于深度学习（Deep Learning, DL）的方法逐渐成为轨迹预测研究的重要方向^[7]。深度学习模型具有强大的非线性表达能力，能够从大规模数据中自动学习复杂的时空特征，从而更准确地建模目标运动行为。在相关研究中，常见的深度学习模型包括序列模型（如 RNN、LSTM、GRU 等）、卷积神经网络（CNN）、图神经网络（GNN）、Transformer 结构以及自动编码器（Autoencoder）和生成对抗网络（GAN）等。其中，序列模型通常用于建模轨迹数据中的时间依赖关系，而图神经网络则能够描述多目标之间的交互关系，Transformer 结构则通过注意力机制捕获长时间依赖信息，从而提升轨迹预测的准确性与鲁棒性。

此外，强化学习（Reinforcement Learning, RL）方法也被逐渐应用于轨迹预测研究中^[8]。该类方法通常将目标运动行为视为一种策略决策过程，通过学习策略函数来生成未来轨迹。在一些研究中，强化学习不仅被用于路径规划任务，也被用于轨迹预测问题。例如，逆强化学习（Inverse Reinforcement Learning, IRL）通过分析专家示范数据来学习潜在的奖励函数，从而推断出目标的行为策略；而模仿学习（Imitation Learning）则直接从专家轨迹数据中学习策略，生成与专家行为相似的预测轨迹。这类方法能够在一定程度上捕获复杂决策行为，但通常需要大量训练数据以及较高的计算资源。

总体而言，基于学习的轨迹预测方法能够通过数据驱动的方式学习复杂的运动模式，在非线性和高维以及多目标交互场景中具有较好的表现。然而，这类方法往往依赖大量训练数据，并且在实时性与可解释性方面仍然存在一定挑战。

1.2.3 传统云台视角规划与控制算法

传统云台视角一般被视为控制问题，研究人员使用了多种控制策略实现云台对目标的实时跟踪。Lee 等人使用 PID 作为控制器，利用视觉中心与目标中心间的误差进行反馈控制^[9]；Wisniewski 使用了强化学习的方式，建立无人机跟踪任务的仿真环境，使用

视觉中心与目标中心间的误差作为观测变量之一，进行强化学习训练^[10]。

但云台视角控制问题一直没有被上升为高层的规划问题，主要原因有以下两点：

1) 传统的视觉无人机检测任务所使用的传感器多为 PTZ 相机，其视场角较小，只能精确跟踪某一架无人机，但是当面对无人机集群等多目标检测问题往往难以应付。

2) 传统的视觉无人机检测任务仅有二维视觉目标检测与跟踪信息，无法生成高置信度的无人机三维位置信息，面对高机动性的弱小无人机目标无法生成可靠的预测信息来规划传感器视角。

1.2.4 需要解决的科学问题

综合上述对当前研究现状的调研，本文提出三项亟待解决的科学问题：

1) 传统单一相机的传感器容易受光照环境变化影响其目标检测结果，且单一二维视觉输入无法检测其三维坐标信息，加之传感器视场角较小无法适应多目标检测场景，因此需要使用视场角较大的抗光照深度传感器进行多传感器融合的目标检测与跟踪。

2) 传统基于单一物理模型的轨迹预测方法难以描述无人机在实际飞行过程中的复杂机动行为，如加速、减速及转弯等运动模式切换，从而导致预测精度下降；而基于深度学习的轨迹预测方法虽然能够学习复杂运动规律，但通常依赖大量训练数据且对计算资源要求较高，不利于在实时监测系统中部署，因此需要研究兼顾预测精度与计算效率的多模型轨迹预测方法。

3) 传统云台控制算法通常针对单目标跟踪进行设计，在多目标监测场景中容易出现频繁切换目标、视角抖动等问题，导致目标观测不稳定甚至发生目标丢失，同时缺乏对目标未来运动趋势的考虑，难以实现对多个目标的持续稳定观测，因此需要研究结合目标状态预测的多目标云台视角规划方法。

2 研究内容

2.1 多传感器融合目标检测与跟踪

为了解决单一相机对光照敏感以及二维视觉无法准确测量检测目标的三维坐标的问题，本文采用车规级激光雷达 Livox-HAP 与海康工业相机 MV-CU050-90UC 构建一体化传感器^[11]，然后设计基于多传感器融合的目标检测与跟踪算法，同时生成由工业相机二维视觉生成的无人机识别与跟踪的语义信息以及由激光雷达测量得到的无人机三维坐标信息。

2.1.1 激光雷达和相机数据的融合策略调研

本文初步调研了自动驾驶领域多传感器融合的目标检测与跟踪算法，激光雷达和相机数据的不同融合方法如图 4 所示^[4]。常见的融合方式主要包括早期融合(Early Fusion)、后期融合(Late Fusion)以及点云增强(Augmenting Point Clouds)等策略。在早期融合方法中，通常先在图像中完成目标检测，然后将激光雷达点云投影到二维图像平面，并

将投影点与图像中的检测目标进行匹配，从而估计目标的深度信息。后期融合方法则是在检测结果层面进行融合，例如将激光雷达检测得到的三维包围框投影到图像平面，并与相机检测得到的二维目标进行对齐，从而综合两种传感器的检测结果。另一种常见方法是点云增强策略^[12]，即将点云投影到图像中，并利用图像特征对点云数据进行补充，从而丰富每个点的语义信息。




图4 激光雷达和相机数据的不同融合方法^[4]

2.1.2 多传感器融合技术路线拟定

为了得到准确可靠的传感器融合信息同时控制算力开销，本文采用后期融合（Late Fusion）的方式进行激光雷达和相机数据的融合^[13]，技术路线如下图所示。




图5 多传感器融合技术路线拟定^[13]

首先，分别从激光雷达与相机中获得对应的二维或三维视觉数据，并分别监测的二维与三维检测框，然后通过交并比、置信度等数据验证二维与三维检测框是否匹配，将

匹配结果最为最后的目标检测结果传递给目标跟踪模块。然后，针对匹配好的二维与三维目标，分别使用开源的 ByteTrack 算法^[14]与 AB3DMOT 算法^[15]进行轨迹跟踪。最后二维视觉通道输出无人机识别、分类的二维语义轨迹，三维视觉通道输出具有可靠位置、速度的三维点云轨迹。

2.2 IMM-KF 轨迹预测算法

为了精准预测高机动性无人机的轨迹，同时不占用太多的算力，本文采用交互式多模型卡尔曼滤波(IMM-KF)^[16]，融合多种模型进行无人机的轨迹预测。IMM-KF 算法原理如下图所示。




图6 IMM-KF 算法原理图

2.2.1 IMM-KF 算法原理

假设目标运动由多个模型 $\mathcal{M} = M_1, M_2, \dots, M_M$ 共同描述，每个模型都有自己的状态估计结果 $\hat{x}_i(k)$, $P_i(k)$ ，其中 i 为模型编号， $\hat{x}_i(k)$ 为模型 i 在 k 时刻的状态估计， $P_i(k)$ 为协方差矩阵。IMM-KF 假设每个时刻下每个模型都有存在的概率 $\mu_i(k)$ ，且满足归一化条件，即 $\sum_{i=1}^M \mu_i(k) = 1$ 。

IMM-KF 作为交互式多模型算法，假设模型之间可以相互转移，其转移概率由下述模型转移概率矩阵表示：

$$\Pi = \begin{bmatrix} p_{11} & p_{12} & \cdots & p_{1M} \\ p_{21} & p_{22} & \cdots & p_{2M} \\ \vdots & \vdots & \ddots & \vdots \\ p_{M1} & p_{M2} & \cdots & p_{MM} \end{bmatrix} \quad (2.1)$$

其中 $p_{ij} = P(M_j(k)|M_i(k-1))$ ，表示上一时刻模型 i 转移到当前模型 j 的概率，同样满足归一化条件，即 $\sum_{j=1}^M p_{ij} = 1$ 。

假设目标上一时刻模型*i*转移到当前模型*j*，则由贝叶斯公式可得该情况的概率为：

$$\mu_{i|j}(k-1) = \frac{p_{ij}\mu_i(k-1)}{c_j}, \quad c_j = \sum_{i=1}^M p_{ij}\mu_i(k-1) \quad (2.2)$$

IMM-KF 利用上述公式求得的条件概率更新每个模型的先验值与先验协方差作为卡尔曼滤波的先验输入，公式如下：

$$\hat{x}_j^0(k-1) = \sum_{i=1}^M \mu_{i|j}(k-1)\hat{x}_i(k-1) \quad (2.3)$$

$$P_j^0(k-1) = \sum_{i=1}^M \mu_{i|j}(k-1) * [P_i(k-1) + (\hat{x}_i(k-1) - \hat{x}_j^0(k-1))(\hat{x}_i(k-1) - \hat{x}_j^0(k-1))^T] \quad (2.4)$$

接下来进行模型概率 $\mu_i(k)$ 的更新，通过使用正态分布公式计算每个模型的似然函数：

$$\Lambda_j(k) = \frac{1}{\sqrt{2\pi|S_j|}} \exp\left(-\frac{1}{2}v_j^T S_j^{-1}v_j\right) \quad (2.5)$$

$$v_j = z_k - H\hat{x}_j^-(k), \quad S_j = HP_j^-(k)H^T + R \quad (2.6)$$

然后使用似然函数对每个模型的概率进行更新：

$$\mu_j(k) = \frac{\Lambda_j(k)c_j}{\sum_{l=1}^M \Lambda_l(k)c_l} \quad (2.7)$$

最后根据每个模型的概率融合多个卡尔曼滤波的后验值，得到最终的滤波结果。

$$\hat{x}(k) = \sum_{j=1}^M \mu_j(k)\hat{x}_j(k) \quad (2.8)$$

$$P(k) = \sum_{j=1}^M \mu_j(k)[P_j(k) + (\hat{x}_j(k) - \hat{x}(k))(\hat{x}_j(k) - \hat{x}(k))^T] \quad (2.9)$$

于是问题来到了如何设计多个运动模型来覆盖无人机运动的各个阶段以及如何设定模型融合矩阵。本文采用以下三个运动模型：匀速运动模型(CV)、匀加速度运动模型(CA)以及 Singer 模型。

2.2.2 匀速运动模型(CV)

匀速运动模型假设目标在短时间内速度保持恒定，仅受到随机扰动影响。其状态向量包含三轴位置与三轴速度，即 $\mathbf{x}_k = [x_k \ y_k \ z_k \ v_{x,k} \ v_{y,k} \ v_{z,k}]^T$

根据运动学公式，可得匀速运动模型的状态转移方程与状态转移矩阵如下所示。

$$\mathbf{x}_{k+1} = F_{CV}\mathbf{x}_k + \mathbf{w}_k, \quad F_{CV} = \begin{bmatrix} 1 & 0 & 0 & \Delta t & 0 & 0 \\ 0 & 1 & 0 & 0 & \Delta t & 0 \\ 0 & 0 & 1 & 0 & 0 & \Delta t \\ 0 & 0 & 0 & 1 & 0 & 0 \\ 0 & 0 & 0 & 0 & 1 & 0 \\ 0 & 0 & 0 & 0 & 0 & 1 \end{bmatrix} \quad (2.10)$$

2.2.3 匀加速度运动模型(CA)

匀加速度运动模型假设目标在短时间内加速度保持恒定，与匀速模型相比估计的变量更多。匀加速度运动模型的状态向量包含三轴位置、速度与加速度信息，即 $\mathbf{x}_k = [x_k \ y_k \ z_k \ v_{x,k} \ v_{y,k} \ v_{z,k} \ a_{x,k} \ a_{y,k} \ a_{z,k}]^T$

根据运动学公式，可得匀加速度运动模型的状态转移方程与状态转移矩阵如下所示。

$$\mathbf{x}_{k+1} = F_{CA}\mathbf{x}_k + \mathbf{w}_k, \quad F_{CA} = \begin{bmatrix} 1 & 0 & 0 & \Delta t & 0 & 0 & \frac{\Delta t^2}{2} & 0 & 0 \\ 0 & 1 & 0 & 0 & \Delta t & 0 & 0 & \frac{\Delta t^2}{2} & 0 \\ 0 & 0 & 1 & 0 & 0 & \Delta t & 0 & 0 & \frac{\Delta t^2}{2} \\ 0 & 0 & 0 & 1 & 0 & 0 & \Delta t & 0 & 0 \\ 0 & 0 & 0 & 0 & 1 & 0 & 0 & \Delta t & 0 \\ 0 & 0 & 0 & 0 & 0 & 1 & 0 & 0 & \Delta t \\ 0 & 0 & 0 & 0 & 0 & 0 & 1 & 0 & 0 \\ 0 & 0 & 0 & 0 & 0 & 0 & 0 & 1 & 0 \\ 0 & 0 & 0 & 0 & 0 & 0 & 0 & 0 & 1 \end{bmatrix} \quad (2.11)$$

2.2.4 Singer 模型

Singer 模型是一种机动目标运动模型，其假设目标加速度会随时间呈指数衰减，能够更好地描述目标机动行为。

Singer 模型的状态向量与匀加速度模型保持一致，包含三轴位置、速度与加速度信息，即 $\mathbf{x}_k = [x_k \ y_k \ z_k \ v_{x,k} \ v_{y,k} \ v_{z,k} \ a_{x,k} \ a_{y,k} \ a_{z,k}]^T$

Singer 模型认为加速度符合一阶马尔科夫过程，即加速度随指数衰减，其状态转移公式可以描述成如下形式：

$$\dot{a}(t) = -\alpha a(t) + w(t) \quad (2.12)$$

于是可得 Singer 模型的状态转移矩阵公式如下：

$$\phi = e^{-\alpha \Delta t}, F_{1D} = \begin{bmatrix} 1 & \Delta t & \frac{1-\phi}{\alpha^2} - \frac{\Delta t}{\alpha} \\ 0 & 1 & \frac{1-\phi}{\alpha} \\ 0 & 0 & \phi \end{bmatrix}, F_{Singer} = \begin{bmatrix} F_{1D} & 0 & 0 \\ 0 & F_{1D} & 0 \\ 0 & 0 & F_{1D} \end{bmatrix} \quad (2.13)$$

2.3 MPC 主动视角规划算法

为了规划云台的视角，本文采用模型预测控制(MPC)算法^[17]进行双轴云台的主动视角规划，使用轨迹预测得到的未来数个时间步长下的目标运动轨迹构建二次规划问题，得到期望的云台视角轨迹。

2.3.1 问题描述

考虑一个安装在固定平台上的双轴云台传感器系统，其云台转角定义为 $\theta = \begin{bmatrix} \psi \\ \phi \end{bmatrix}$ ，其中 ψ 为云台 yaw 角， ϕ 为云台 pitch 角。

假设 k 时刻存在 M 个被跟踪目标，每个目标由滤波器给出其三维坐标 $p_{i,k} = (x_{i,k}, y_{i,k}, z_{i,k})$ ，则对应的理想观测云台转角可以有如下公式得出：

$$\theta_{i,k} = \begin{bmatrix} \psi_{i,k} \\ \phi_{i,k} \end{bmatrix}, \psi_{i,k} = \arctan2(y_{i,k}, x_{i,k}), \phi_{i,k} = \arctan2\left(z_{i,k}, \sqrt{x_{i,k}^2 + y_{i,k}^2}\right) \quad (2.14)$$

针对云台运动速度，由于 MPC 用于规划视角而非直接控制电机，可以采用简化的角度动态模型为匀速运动模型，云台双轴角速度由如下公式给出：

$$u_k = \begin{bmatrix} \dot{\psi}_k \\ \dot{\phi}_k \end{bmatrix}, \theta_{k+1} = \theta_k + u_k \Delta t \quad (2.15)$$

此时可以将该规划问题抽象为如下优化问题：定义预测窗口长度为 N ，则 N 个时间步长下目标轨迹预测序列为 $\theta_{i,1}, \theta_{i,2}, \dots, \theta_{i,N}$ ，优化目标为未来 N 步云台角度序列 $\Theta = \{\theta_1, \theta_2, \dots, \theta_N\}$

2.3.2 代价函数构建

根据实际工况，本文初步设定该规划问题的代价函数如下：

$$J = \sum_{i=1}^M w_i \sum_{k=1}^N \|\theta_k - \theta_{i,k}\|^2 + \lambda_1 \sum_{k=1}^N \|\theta_k - \theta_{k-1}\|^2 + \lambda_2 \sum_{k=1}^N \|u_k - u_{k-1}\|^2 \quad (2.16)$$

主要分为三项：

1) 目标视角跟踪项 $J_{track} = \sum_{i=1}^M w_i \sum_{k=1}^N \|\theta_k - \theta_{i,k}\|^2$ ，其中各个目标的权重 w_i 由置信度、目标尺寸等信息综合计算得到。

2) 视角平滑项 $J_{smooth} = \sum_{k=1}^N \|\theta_k - \theta_{k-1}\|^2$ 。

3) 控制输入惩罚 $J_{control} = \sum_{k=1}^N \|u_k - u_{k-1}\|^2$ ，其中 $u_k = \frac{\theta_k - \theta_{k-1}}{\Delta t}$ 。

同时，为了确保优化结果不越界，设计约束条件如下：

$$\begin{cases} \psi_{min} \leq \psi_k \leq \psi_{max} \\ \phi_{min} \leq \phi_k \leq \phi_{max} \\ |u_k| \leq u_{max} \end{cases} \quad (2.17)$$

经如上分析，该云台主动视角规划问题已成功转化为有约束二次规划问题，方便调用开源 MPC 优化库进行求解。

3 研究方案

3.1 研究方法与技术途径

本课题拟采用理论研究与仿真实验相结合的研究方法。首先对弱小无人机目标检测与跟踪领域的相关算法进行系统学习与研究，在此基础上针对复杂环境下弱小目标难以稳定检测的问题，使用激光雷达与相机进行多传感器融合^[13]的方式对目标检测与多目标

跟踪算法进行改进与优化，提高系统在干扰环境中的检测精度与跟踪稳定性。随后在目标状态估计的基础上，引入轨迹预测模型，对目标未来运动状态进行预测，并结合交互式多模型滤波^[16]方法提升预测精度。进一步地，针对搭载传感器的双轴云台设备，研究基于模型预测控制(MPC)^[17]的云台视角规划方法，使系统在多目标场景下能够合理规划传感器视角，实现对重要目标的持续稳定观测。最后搭建包含无人机目标的仿真环境，对目标检测、跟踪、轨迹预测及云台视角规划算法进行系统仿真实验验证，评估算法在复杂环境下的可行性与鲁棒性。

3.2 研究的创新之处

本研究可能的创新之处如下：

- 1) 使用多传感器融合进行无人机视觉检测与跟踪，使视觉反无系统可以适应更复杂的光照环境，同时扩大了视场角，增强了视觉反无系统的多目标检测与跟踪能力。
- 2) 使用交互式多模态卡尔曼滤波(IMM-KF)进行无人机轨迹预测，提高了对无人机轨迹预测的准确性。
- 3) 针对多目标场景使用 MPC 进行云台的主动视角规划，保证对无人机这种远距离弱小飞行目标的实时追踪。

4 研究计划及预期成果

4.1 研究计划

研究计划如下列表格所示。

主要工作内容	开始时间	结束时间
完成激光雷达目标检测模块的构建	2026.3.9	2026.3.16
完成多传感器检测结果融合	2026.3.17	2026.3.24
完成目标跟踪模块的构建	2026.3.25	2026.4.1
进行多传感器融合下目标检测跟踪实验	2026.4.2	2026.4.5
撰写中期报告，准备中期答辩	2026.4.6	2026.4.12
完成轨迹预测模块	2026.4.13	2026.4.20
完成主动视角规划算法模块	2026.4.21	2026.4.28
进行主动视角规划实验	2026.4.29	2026.5.3
进一步完善内容，撰写毕业论文	2026.5.4	2026.5.20

4.2 预期成果

根据现有的视觉反无人机检测与跟踪研究现状和任务要求进行分析，对本课题的预期目标如下：

- 1) 设计多传感器目标检测与跟踪算法，同时获取无人机检测跟踪的语义信息和 3D

视觉计算得出的无人机实时位置信息。

2) 设计交互式多模态卡尔曼滤波(IMM-KF)，使用多种运动模型预测无人机的运动轨迹。

3) 设计基于 MPC 的云台主动视角规划算法，针对多目标检测与跟踪的任务场景设计代价函数。

参考文献

- [1] WANG B, LI Q, MAO Q, 等. A Survey on Vision-Based Anti Unmanned Aerial Vehicles Methods[J/OL]. Drones, 2024, 8(9)[2026-03-01]. <https://www.mdpi.com/2504-446X/8/9/518>.
- [2] DING G, REN Y, LIU Y, 等. Vision-Based Anti-Unmanned Aerial Technology: Opportunities and challenges[J]. IEEE Geoscience and Remote Sensing Magazine, 2025, 13(4): 382-405.
- [3] JIANG N, WANG K, PENG X, 等. Anti-UAV: A Large-Scale Benchmark for Vision-Based UAV Tracking[J]. IEEE Transactions on Multimedia, 2023, 25: 486-500.
- [4] MADJID N A, AHMAD A, MEBRAHTU M, 等. Trajectory Prediction for Autonomous Driving: Progress, Limitations, and Future Directions[J]. Information Fusion, 2026, 126: 103588.
- [5] ANDERSON C, VASUDEVAN R, JOHNSON-ROBERSON M. A Kinematic Model for Trajectory Prediction in General Highway Scenarios[J]. IEEE Robotics and Automation Letters, 2021, 6(4): 6757-6764.
- [6] AMMOUN S, NASHASHIBI F. Real time trajectory prediction for collision risk estimation between vehicles[C/OL]//2009 IEEE 5th International Conference on Intelligent Computer Communication and Processing. 2009: 417-422[2026-03-11]. <https://ieeexplore.ieee.org/document/5284727>.
- [7] LIU J, MAO X, FANG Y, 等. A Survey on Deep-Learning Approaches for Vehicle Trajectory Prediction in Autonomous Driving[C/OL]//2021 IEEE International Conference on Robotics and Biomimetics (ROBIO). 2021: 978-985[2026-03-12]. <https://ieeexplore.ieee.org/abstract/document/9739407>.
- [8] HE C, CHEN L, XU L, 等. IRLSOT: Inverse reinforcement learning for scene-oriented trajectory prediction[J]. IET Intelligent Transport Systems, 2022, 16(6): 769-781.
- [9] LEE H, LIM D, HAN S H, 等. An empirical study of PTZ camera-based drone tracking under latency and detector challenges[J]. Machine Vision and Applications, 2025, 36(4): 84.
- [10] WISNIEWSKI M, RANA Z A, PETRUNIN I, 等. Towards Fully Autonomous Drone Tracking by a Reinforcement Learning Agent Controlling a Pan-Tilt-Zoom Camera[J/OL]. Drones, 2024, 8(6)[2026-03-03]. <https://www.mdpi.com/2504-446X/8/6/235>.
- [11] YUAN S, YANG Y, NGUYEN T H, 等. MMAUD: A Comprehensive Multi-Modal Anti-UAV Dataset for Modern Miniature Drone Threats[C/OL]//2024 IEEE International Conference on Robotics and Automation (ICRA). 2024: 2745-2751[2026-03-02]. <http://arxiv.org/abs/2402.03706>.
- [12] LIU Z, TANG H, AMINI A, 等. BEVFusion: Multi-Task Multi-Sensor Fusion with Unified Bird's-Eye View Representation[EB/OL]. arXiv, 2024[2026-02-28]. <http://arxiv.org/abs/2205.13542>.
- [13] XU Z, SHEN H, HAN X, 等. LV-DOT: LiDAR-visual dynamic obstacle detection and tracking for autonomous robot navigation[EB/OL]. arXiv, 2025[2026-02-03]. <http://arxiv.org/abs/2502.20607>.
- [14] ZHANG Y, SUN P, JIANG Y, 等. ByteTrack: Multi-Object Tracking by Associating

- Every Detection Box[EB/OL]. arXiv, 2022[2026-03-11]. <http://arxiv.org/abs/2110.06864>.
- [15] WENG X, WANG J, HELD D, 等. AB3DMOT: A Baseline for 3D Multi-Object Tracking and New Evaluation Metrics[EB/OL]. arXiv, 2020[2026-03-11]. <http://arxiv.org/abs/2008.08063>.
- [16] PAILLET P, AUDIGIER R, LERASLE F, 等. IMM-Based Tracking and Latency Control with Off-the-Shelf IP PTZ Camera[C]//BLANC-TALON J, KASINSKI A, PHILIPS W, 等. Advanced Concepts for Intelligent Vision Systems. Cham: Springer International Publishing, 2013: 564-575.
- [17] REN B, CHEN H, ZHAO H, 等. MPC-based yaw stability control in in-wheel-motored EV via active front steering and motor torque distribution[J]. Mechatronics, 2016, 38: 103-114.